

<복제물에 대한 경고>

본 저작물은 **저작권법 제25조 수업목적 저작물 이용 보상금제도**에 의거, **한국복제전송저작권협회**와 약정을 체결하고
적법하게 이용하고 있습니다. 약정범위를 초과하는 사용은 저작권법에 저촉될 수 있으므로

저작물의 재 복제 및 수업 목적 외의 사용을 금지합니다.

2020. 03. 30.

건국대학교(서울)한국복제전송저작권협회

<전송에 대한 경고>

본 사이트에서 수업 자료로 이용되는 저작물은 **저작권법 제25조 수업목적 저작물 이용 보상금제도**에 의거,

한국복제전송저작권협회와 약정을 체결하고 적법하게 이용하고 있습니다.

약정범위를 초과하는 사용은 저작권법에 저촉될 수 있으므로

수업자료의 대중 공개·공유 및 수업 목적 외의 사용을 금지합니다.

2020. 03. 30.

건국대학교(서울)한국복제전송저작권협회

Support Vector Machine


SVM (Support Vector Machine)

- SVM

- 데이터들을 커널함수(kernel function)를 이용하여 고차원 공간으로 사상시킨 후 support vector들로 이루어진 초평면을 이용하여 선형 분류하는 마진 기반 기계학습 모델

- 예제: XOR

- 2차원 XOR 좌표를 이등분하는 초평면을 찾는 문제



Edited by Harksoo Kim

커널 함수 (Kernel Function)

- 커널 함수


- 저차원 데이터를 고차원 공간으로 사상(mapping)시키는 함수
- 예제

x (입력)	y (출력)
0	O
0.5	X
0.6	X
1	O


커널 함수
 $f(x) = x^2$



x (입력)	f(x)	y (출력)
0	0	O
0.5	0.25	X
0.6	0.36	X
1	1	O



1차원



2차원




Edited by Harksoo Kim


커널 함수 (Kernel Function)

- 커널 함수의 기능


- 선형 분리 불가능 문제를 선형 분리 가능 문제로 변환
- 선형 분리 가능 문제 (linear separable problem)
 - 한 개의 직선(초평면)으로 분리할 수 있는 문제



Linear separable? No!



Linear separable? Yes!



Edited by Harksoo Kim


지지 벡터 (Support Vectors)

- SVM

- 데이터들을 커널함수(Kernel function)를 이용하여 고차원 공간으로 사상시킨 후 **support vector**들로 이루어진 초평면을 이용하여 선형 분류하는 마진 기반 기계학습 모델

- 지지 벡터


- 선형 분류(linear classification)의 경계 주변에 존재하는 데이터 포인트들
- 이진 선형 분류 문제에서는 수많은 support vector들이 존재



Edited by Harksoo Kim

최대 마진 (Maximum Margin)

- SVM
 - 데이터들을 커널함수(Kernel function)를 이용하여 고차원 공간으로 사상시킨 후 support vector들로 이루어진 초평면을 이용하여 선형 분류하는 **마진 기반 기계학습 모델**
- 최대 마진
 - 선형 분류를 가능하게 하는 직선은 무수히 많이 존재
 - 그 중에서 마진을 최대로 하는 직선이 가장 이상적 임




Which one is the best?
The answer is **the blue line**.



Edited by Harksoo Kim

최대 마진 (Maximum Margin)



(1) 학습 데이터

$$\mathbf{w} \mathbf{x}^+ + b = +1$$

$$\mathbf{w} \mathbf{x}^- + b = -1$$

$$\mathbf{x}^+ = \mathbf{x}^- + \lambda \mathbf{w}$$

$$|\mathbf{x}^+ - \mathbf{x}^-| = M$$

(2) 수식 유도

$$\mathbf{w} (\mathbf{x}^- + \lambda \mathbf{w}) + b = 1 \quad M = |\mathbf{x}^+ - \mathbf{x}^-| = |\lambda \mathbf{w}| =$$

$$\mathbf{w} \mathbf{x}^- + b + \lambda \mathbf{w} \mathbf{w} = 1 \quad = \lambda |\mathbf{w}| = \lambda \sqrt{\mathbf{w} \cdot \mathbf{w}}$$

$$-1 + \lambda \mathbf{w} \mathbf{w} = 1$$

$$\lambda = \frac{2}{\mathbf{w} \cdot \mathbf{w}} \quad = \frac{2\sqrt{\mathbf{w} \cdot \mathbf{w}}}{\mathbf{w} \cdot \mathbf{w}} = \frac{2}{\sqrt{\mathbf{w} \cdot \mathbf{w}}}$$

$$= \frac{2}{\|\mathbf{w}\|}$$

(3) 목적 함수

M을 최대화하는 것 \rightarrow $\|\mathbf{w}\|$ 를 최소화하는 것!



Edited by Harksoo Kim

최적화 문제 (Optimization Problem)

- Primal Problem (주어진 원래 문제)

$$F(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} - b \quad \& \quad \mathbf{w} \cdot \mathbf{x}_i - b > 0 \text{ if } y_i = 1, \text{ and} \\ \mathbf{w} \cdot \mathbf{x}_i - b < 0 \text{ if } y_i = -1$$

$$\begin{aligned} \text{minimize: } Q(\mathbf{w}) &= \frac{1}{2} \|\mathbf{w}\|^2 && \leftarrow \text{목적함수: Convex function of } \mathbf{w} \\ \text{subject to: } y_i(\mathbf{w} \cdot \mathbf{x}_i - b) &= 1, \forall (\mathbf{x}_i, y_i) \in D && \leftarrow \text{제약조건: Linear in } \mathbf{w} \end{aligned}$$

\mathbf{w} 와 b 에 대한 최소값 = 정점
→ 미분을 했을 때 기울기가 0인 곳!

★ 주어진 제약하에서 목적함수의 최소값을 구하는 문제? Lagrange function

$$\text{Condition 1: } \frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = 0$$

$$\text{Condition 2: } \frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0$$

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w} \cdot \mathbf{w} - \sum_{i=1}^m \alpha_i \{y_i(\mathbf{w} \cdot \mathbf{x}_i - b) - 1\}$$

Lagrange multiplier

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad \& \quad \sum_{i=1}^m \alpha_i y_i = 0$$



Edited by Harksoo Kim

최적화 문제 (Optimization Problem)

- Dual Problem (쌍대 문제)

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w} \cdot \mathbf{w} - \sum_{i=1}^m \alpha_i \{y_i(\mathbf{w} \cdot \mathbf{x}_i - b) - 1\} \quad \& \quad \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad \& \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w} \cdot \mathbf{w} - \sum_{i=1}^m \alpha_i y_i \mathbf{w} \cdot \mathbf{x}_i + b \sum_{i=1}^m \alpha_i y_i - \sum_{i=1}^m \alpha_i$$

$$\mathbf{w} \cdot \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i = \mathbf{w} \cdot \mathbf{w}$$

$$\text{Let } J(\mathbf{w}, b, \alpha) = Q(\alpha)$$

$$Q(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i \cdot \mathbf{x}_j$$

★ \mathbf{w} 와 b 에 대한 최소값 = α 에 대한 최대값!

$$\text{maximize: } Q(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i \cdot \mathbf{x}_j$$

$$\begin{aligned} \text{subject to: } \quad & \sum_i \alpha_i y_i = 0 \\ & \alpha_i \geq 0 \end{aligned}$$

\mathbf{w} 가 없어지고 training data에서 얻을 수 있는 것으로 모두 바뀌었다!



Edited by Harksoo Kim

최적화 문제 (Optimization Problem)

maximize: $Q(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j v_i v_j \mathbf{x}_i \mathbf{x}_j$ ★ Lagrange multiplier → 편미분 ?

subject to: $\sum_i \alpha_i v_i = 0$
 $\alpha \geq 0$

↓
 제약사항이 부등식이면? 쿤-터커 정리 적용

번호	조건식	풀이
1	$\frac{\partial L}{\partial x_i} = f_i - \sum_{k=1}^m \lambda_k g_i^k \leq 0$	라그랑지안 함수를 각 변수 x_i 로 편미분한 결과는 극값에서 음이거나 0이어야 한다.
2	$\frac{\partial L}{\partial \lambda_i} = r_i - g^k \geq 0$	라그랑지안 함수를 라그랑지 승수로 편미분한 결과는 비음이어야 한다.
3	$x_i (\frac{\partial L}{\partial x_i}) = x_i (f_i - \sum_{k=1}^m \lambda_k g_i^k) = 0$	최적해에서 변수 x_i 와 $\frac{\partial L}{\partial x_i}$ 를 곱한 값이 0이어야 한다.
4	$\lambda_i (\frac{\partial L}{\partial \lambda_i}) = \lambda_i (r_i - g^k) = 0$	최적해에서 변수 λ_i 와 $\frac{\partial L}{\partial \lambda_i}$ 를 곱한 값이 0이어야 한다.
5	$x_i \geq 0$	최적해에서 변수는 비음이어야 한다.
6	$\lambda_i \geq 0$	최적해에서 라그랑지안 승수는 비음이어야 한다.

Finally $F(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} - b \xrightarrow{\quad} F(\mathbf{x}) = \sum_i \alpha_i v_i \mathbf{x}_i \cdot \mathbf{x} - b$ 즉, $Q(\mathbf{w}) = Q(\alpha)$



Edited by Harksoo Kim

커널 트릭 (Kernel Trick)

• 커널 트릭

- SVM 함수는 고차원 공간에서의 내적을 통해서 구현

$$F(\mathbf{x}) = \sum_i \alpha_i v_i \boxed{\varphi(\mathbf{x}_i) \cdot \varphi(\mathbf{x})} - b$$

고차원 공간으로 사상한 후 내적 수행

- 고차원 공간으로 사상하고 내적을 구하는 것은 매우 복잡
- 현재 차원에서 동일한 효과를 거두는 커널 함수를 사용 → 트릭

Mercer의 이론에 따르면 다음 조건을 만족하면 대체 가능

$$\int K(\mathbf{u}, \mathbf{v}) \psi(\mathbf{u}) \psi(\mathbf{v}) d\mathbf{x} d\mathbf{y} \leq 0$$

where $\int \psi(\mathbf{x})^2 d\mathbf{x} \leq 0$




- Polynomial: $K(a, b) = (a \cdot b + 1)^d$
- Radial Basis Function (RBF): $K(a, b) = \exp(-\gamma \|a - b\|^2)$
- Sigmoid: $K(a, b) = \tanh(\kappa a \cdot b + c)$

잘 알려진 커널 트릭 함수들!



Edited by Harksoo Kim

확인 예제



XOR problem
(선형 분리 불가능)

x_1	x_2	y
-1	-1	-1
-1	+1	+1
+1	-1	+1
+1	+1	-1

커널 트릭 함수

$$K(\mathbf{x}, \mathbf{x}_i) = (1 + \mathbf{x} \cdot \mathbf{x}_i)^2$$

$$K(\mathbf{x}, \mathbf{x}_i) = 1 + x_1^2 x_{i1}^2 + 2x_1 x_2 x_{i1} x_{i2} + x_2^2 x_{i2}^2 + 2x_1 x_{i1} + 2x_2 x_{i2}$$

고차원 사상 효과

$$\phi(\mathbf{x}) = (1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2)$$



Edited by Harksoo Kim

확인 예제

$$\text{maximize: } Q_2(\alpha) = \sum_i \alpha_i - \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

$$\text{subject to: } \sum_i \alpha_i y_i = 0$$

$$C \geq \alpha \geq 0$$

$$Q(\alpha) = \alpha_1 + \alpha_2 + \alpha_3 + \alpha_4$$

$$- \frac{1}{2} (9\alpha_1^2 - 2\alpha_1\alpha_2 - 2\alpha_1\alpha_3 + 2\alpha_1\alpha_4$$

$$+ 9\alpha_2^2 + 2\alpha_2\alpha_3 - 2\alpha_2\alpha_4 + 9\alpha_3^2 - 2\alpha_3\alpha_4 + \alpha_4^2)$$

Lagrange multipliers (각 α 의 미분=0)

$$9\alpha_1 - \alpha_2 - \alpha_3 + \alpha_4 = 1$$

$$-\alpha_1 + 9\alpha_2 + \alpha_3 - \alpha_4 = 1$$

$$-\alpha_1 + \alpha_2 + 9\alpha_3 - \alpha_4 = 1$$

$$\alpha_1 - \alpha_2 - \alpha_3 + 9\alpha_4 = 1$$



$$\alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \frac{1}{8}$$

$$Q(\alpha) = \frac{1}{4}$$

$$\frac{1}{2} \|w\|^2 = \frac{1}{4}, \quad \text{or} \quad \|w\| = \frac{1}{\sqrt{2}}$$



Edited by Harksoo Kim

확인 예제

$$\mathbf{w} = \sum \alpha_i y_i \phi(\mathbf{x}_i) \& \phi(\mathbf{x}) = (1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2) \& \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \frac{1}{8}$$

$$\mathbf{w} = \frac{1}{8} [-\phi(\mathbf{x}_1) + \phi(\mathbf{x}_2) + \phi(\mathbf{x}_3) - \phi(\mathbf{x}_4)]$$

$$= \frac{1}{8} \left[\begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ -\sqrt{2} \\ -\sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ -\sqrt{2} \\ \sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ \sqrt{2} \\ -\sqrt{2} \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ \sqrt{2} \\ \sqrt{2} \end{bmatrix} \right] = \begin{bmatrix} 0 \\ 0 \\ -\frac{1}{\sqrt{2}} \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

(-1,+1), (+1,-1)

● +1

$-x_1x_2 = 0$

■ -1

(-1,-1), (+1,+1)

SVM 함수

$$\mathbf{w} \cdot \phi(\mathbf{x}) - b = 0$$



$$\mathbf{w} \cdot \phi(\mathbf{x}) = \begin{bmatrix} 0 & 0 & -\frac{1}{\sqrt{2}} & 0 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \end{bmatrix} = 0$$



$$-x_1x_2 = 0$$



Edited by Harksoo Kim

SVM에 적합한 문제

- 선형 분류 문제: DT = NN = SVM
- 비선형 분류 문제: NN >= SVM
- 비선형 분류 문제 → 고차원에서의 선형 분류 문제: SVM >>= DT, NN (속도 & 성능)



Edited by Harksoo Kim

질의응답

Q & A

Homepage: <http://nlp.konkuk.ac.kr>
E-mail: nlpdrkim@konkuk.ac.kr



Edited by Harksoo Kim